

**Graduação em Sistemas de Informação - UFU**

**Disciplina:** FACOM31701 - Trabalho de Conclusão de Curso 1

**Professor:** Prof. Dr. Rafael Pasquini

**Aluno(a):** Paula Prado Carvalho

**Orientador(a):** Prof.(a) Christiane Regina Soares Brasil

## **Entrega 2 (E2) - Visão geral sobre a fundamentação teórica**

1) Identifique, juntamente com o seu orientador(a), quais são os principais conceitos teóricos associados ao seu trabalho. Exemplo 1: se o tema do trabalho é o uso de algoritmos genéticos para análise de risco de crédito, então os principais conceitos são: algoritmos genéticos e análise de risco de crédito. Exemplo 2: se o tema do trabalho é o desenvolvimento de um chatbot para atender a comunidade UFU, então os principais conceitos são: processamento de linguagem natural, chatbots e formas de atendimento à comunidade comumente feitas pelas universidades.

**Resposta:**

2) Escreva sobre cada um dos conceitos identificados na pergunta anterior. Use a seguinte estratégia: i) forneça as principais definições, ii) apresente um breve histórico, iii) discuta os avanços recentes da área e iv) mostre alguns exemplos. O objetivo aqui é ter um rascunho do Capítulo 2 - Fundamentação Teórica. Portanto, é de suma importância analisar outras monografias para entender o que deve e o que não ser escrito em tal capítulo.

**Observações:**

1. Os quatro itens apresentados anteriormente precisam formar um texto coeso sobre o assunto.
2. Use o formato de citações do Latex. Um tutorial de como utilizar o overleaf está disponível em ([OVERLEAF, 2025](#)). Note que neste modelo que foi fornecido para a entrega 1, além do arquivo main.tex que será utilizado para redigir seu texto, há um arquivo chamado ref.bib que contém algumas referências como exemplo.
3. Use mais de uma fonte/referência para escrever sobre cada um dos conceitos.
4. Junto da entrega, o aluno deverá anexar um comprovante de concordância do seu orientador quanto ao texto sendo submetido. O comprovante de concordância poderá ser um e-mail do seu orientador, onde ele manifesta autorização para submeter

o texto, ou uma assinatura digital do orientador, por exemplo, gov.br no PDF submetido.

# 1 RASCUNHO DA FUNDAMENTAÇÃO TEÓRICA

## 1.1 Algoritmos Evolutivos

O conceito de evolução natural, popularizado por Charles Darwin em sua obra publicada em 1859, *A Origem das Espécies*, representou uma ruptura no entendimento sobre a origem e o desenvolvimento da vida. Ao defender que os organismos se transformam ao longo do tempo por meio da seleção natural — um processo em que características vantajosas aumentam as chances de sobrevivência e reprodução — Darwin inaugurou uma nova perspectiva sobre a adaptação e a diversidade biológica. Essa visão serviu de inspiração, mais de um século depois, para o surgimento de técnicas computacionais baseadas em princípios evolutivos.

Dentre essas técnicas, destacam-se os algoritmos genéticos, formalizados por John Holland na década de 1970. Buscando resolver problemas de alta complexidade e custo computacional elevado, Holland propôs um método não determinístico que simula, de forma abstrata, o processo de evolução biológica. Nesse contexto, cada solução potencial de um problema é representada como um indivíduo dentro de uma população. Ao longo das gerações, os indivíduos mais bem avaliados com base em uma função de aptidão têm maior probabilidade de contribuir para a formação da próxima geração, por meio de operadores inspirados na genética, como o cruzamento (crossover) e a mutação ([HOLLAND, 1992](#); [EIBEN; SMITH, 2015](#)).

O funcionamento desses algoritmos baseia-se em ciclos iterativos de seleção, reprodução e substituição. Inicialmente, uma população é criada, geralmente de forma aleatória, e suas soluções são avaliadas conforme critérios de desempenho. As melhores são selecionadas para gerar novas combinações, buscando soluções mais eficientes. Para preservar a diversidade e evitar convergência prematura, pequenas mutações aleatórias são introduzidas nas soluções geradas. Esse processo se repete até que um critério de parada seja atingido, como o número de gerações ou a estabilidade da população ([GABRIEL; DELBEM, 2008](#); [COELLO, 2009](#)).

Com o avanço das aplicações, observou-se que muitos problemas reais envolvem múltiplos objetivos conflitantes, para os quais a abordagem tradicional de otimização escalar se mostrava insuficiente. Assim, surgiram os algoritmos genéticos multiobjetivo (AGMOs), capazes de lidar simultaneamente com diversos critérios de avaliação. Esses algoritmos buscam não apenas uma única solução ótima, mas um conjunto de soluções eficientes, conhecidas como Fronteira de Pareto, em que nenhuma solução é superior a

outra em todos os aspectos considerados.

Esse paradigma evolutivo passou a constituir uma base sólida para resolver problemas complexos em diversas áreas do conhecimento, consolidando os algoritmos evolutivos como ferramentas versáteis e poderosas na ciência da computação e na inteligência artificial.

## 1.2 Fronteira de Pareto

Em problemas de otimização que envolvem múltiplos objetivos — muitas vezes conflitantes entre si — não existe, via de regra, uma única solução que seja a melhor em todos os critérios simultaneamente. Para lidar com esse cenário, introduz-se o conceito de Fronteira de Pareto, um conjunto que reúne as soluções consideradas ótimas do ponto de vista multiobjetivo ([VELDHUIZEN; LAMONT; OVELDHUIZENTHERS, 1998](#)).

Formalmente, a Fronteira de Pareto é composta pelas soluções não dominadas em relação às demais, ou seja, aquelas para as quais não existe outra solução que seja melhor em todos os objetivos ao mesmo tempo. Assim, uma solução é dita dominante sobre outra quando ela apresenta desempenho superior em pelo menos um critério sem ser inferior nos demais. O conjunto de todas as soluções não dominadas forma, portanto, uma espécie de "curva de equilíbrio" no espaço das soluções, conhecida como Fronteira de Pareto ([VELDHUIZEN; LAMONT; OVELDHUIZENTHERS, 1998](#)).

Em termos matemáticos, esse conceito pode ser compreendido por duas condições fundamentais ([COELLO, 2009](#)):

1. Para qualquer solução  $x$  na fronteira  $P$ , não existe outra solução  $y$  tal que todas as funções objetivo de  $y$  sejam menores ou iguais às de  $x$ .
2. E deve existir pelo menos uma função objetivo em que  $y$  seja estritamente melhor que  $x$ .

Uma maneira intuitiva de compreender esse conceito é por meio de situações cotidianas que envolvem múltiplos critérios de escolha, como a seleção de um plano de internet. Suponha que uma pessoa deseje contratar um serviço considerando dois objetivos principais: velocidade de download e preço mensal. Planos com maior velocidade costumam ter um custo mais elevado, enquanto opções mais acessíveis tendem a oferecer uma conexão mais lenta. A Fronteira de Pareto, nesse contexto, seria composta pelos planos que proporcionam o melhor equilíbrio entre velocidade e preço — ou seja, aqueles que não são superados simultaneamente por nenhum outro plano nos dois critérios. Cada ponto da fronteira representa uma escolha eficiente, e a decisão final dependerá das prioridades individuais do usuário, uma vez que não existe uma única opção absolutamente superior ([MARSON et al., 2017; VELDHUIZEN; LAMONT; OVELDHUIZENTHERS, 1998](#)).

Em algoritmos genéticos multiobjetivo, o principal desafio é encontrar ou se aproximar dessa fronteira, maximizando a diversidade e a qualidade das soluções ao longo do processo evolutivo. Dessa forma, a Fronteira de Pareto não define uma única resposta ótima, mas sim um conjunto de soluções equivalentes em termos de eficiência, permitindo que a decisão final considere preferências específicas ou restrições contextuais.

### 1.3 Algoritmos Evolutivos Multi-Objetivos

Em problemas de otimização, a avaliação das soluções geralmente é feita por meio de uma função de aptidão, que orienta o processo de busca por alternativas mais eficientes. No entanto, quando há múltiplos objetivos em conflito, como ocorre em muitos cenários reais, essa avaliação exige abordagens mais sofisticadas, levando ao desenvolvimento de algoritmos evolutivos capazes de tratar simultaneamente diversos critérios de desempenho.

No entanto, essa lógica se torna mais sofisticada quando se trata de problemas com múltiplos objetivos simultâneos, dando origem aos chamados algoritmos evolutivos multiobjetivo (AEMOs). A distinção fundamental entre os AGs tradicionais e os AEMOs está na forma como a aptidão dos indivíduos é determinada. Em vez de uma única métrica de avaliação, os AEMOs lidam com vetores de objetivos, recorrendo a conceitos como dominância de Pareto para comparar soluções (BUENO; OLIVEIRA, 2010).

Um dos primeiros algoritmos genéticos adaptados para esse contexto foi o VEGA (Vector Evaluated Genetic Algorithm), proposto por Schaffer em 1985. Essa abordagem avaliava cada objetivo de forma isolada, gerando subconjuntos parciais de soluções. Apesar de pioneiro, o VEGA apresentava como limitação a baixa diversidade entre as soluções geradas, o que comprometia a representatividade da fronteira de Pareto.

Buscando superar essas deficiências, (GOLDBERG, 1989) introduziu uma estratégia baseada diretamente no conceito de dominância: a aptidão de uma solução passou a ser proporcional à quantidade de outras soluções que ela domina — ou seja, aquelas que ela supera em pelo menos um objetivo sem ser inferior nos demais. Essa lógica favorece soluções mais eficientes e bem posicionadas em relação à fronteira.

Entre os algoritmos multiobjetivo mais influentes e amplamente utilizados até os dias atuais estão o NSGA-II (Non-Dominated Sorting Genetic Algorithm II), desenvolvido por (DEB, 2001), e o SPEA-II (Strength Pareto Evolutionary Algorithm II), proposto por (ZITZLER; LAUMANN; THIELE, 2001). Ambos se destacam pelo desempenho robusto em problemas com dois ou três objetivos. O NSGA-II organiza a população por níveis de não dominância e utiliza uma métrica de crowding distance para preservar a diversidade entre as soluções. Já o SPEA-II adota uma abordagem baseada em distâncias euclidianas entre os indivíduos, combinando dominância e densidade para avaliar a aptidão e conduzir a seleção evolutiva (DEB, 2001; ZITZLER; LAUMANN; THIELE, 2001).

Essas estratégias consolidaram os AEMOs como ferramentas essenciais na resolução de problemas reais com múltiplos critérios conflitantes, possibilitando a obtenção de soluções equilibradas e diversificadas dentro do espaço de busca ([NASCIMENTO, 2025](#)).

## 1.4 Algoritmos Evolutivos com Muitos Objetivos

Inicialmente, os algoritmos evolutivos multiobjetivo foram projetados para lidar com problemas envolvendo dois ou três objetivos, com o intuito de aproximar a Fronteira de Pareto de forma eficaz. Após essa aproximação, é comum recorrer a um tomador de decisão — humano ou automatizado — para selecionar a solução mais adequada de acordo com preferências específicas. Contudo, à medida que o número de objetivos aumenta, especialmente acima de quatro, surgem desafios significativos: a diversidade de soluções cresce de forma exponencial e a escolha da solução final torna-se substancialmente mais complexa ([GOULART; CAMPELO, 2016](#)).

Diante dessas dificuldades, surgiu uma subárea dos algoritmos evolutivos conhecida como many-objective optimization, voltada especificamente para problemas com um grande número de objetivos simultâneos ([CHAND; WAGNER, 2015](#)). Diferentemente dos métodos tradicionais, esses algoritmos buscam estratégias mais eficientes para manter a diversidade, reduzir a complexidade computacional e facilitar o processo de decisão.

Apesar da relevância prática, não há um consenso rígido quanto ao número de objetivos que distingue um problema "multiobjetivo" de um "many-objective" ([COELLO, 2009](#)). A delimitação, na prática, ocorre quando os algoritmos clássicos de otimização multiobjetivo deixam de produzir resultados satisfatórios. Ainda assim, por convenção, adota-se geralmente que problemas com mais de quatro objetivos ( $m > 4$ ) já se enquadram na categoria de many-objective.

Os problemas com muitos objetivos apresentam desafios que vão além dos enfrentados em cenários com poucos objetivos. Conforme destacado por ([CHAND; WAGNER, 2015](#)), tais problemas implicam uma maior dificuldade em manter boa convergência à Fronteira de Pareto, assegurar diversidade nas soluções e controlar o custo computacional da otimização. Esses desafios surgiram à medida que muitos dos métodos clássicos de otimização evolutiva para dois ou três objetivos começaram a demonstrar desempenho insuficiente em cenários mais complexos. Diante disso, os Algoritmos Evolutivos com Muitos Objetivos (MaOEAs), abrangem novas estratégias capazes de lidar de forma mais eficiente com o grande número de objetivos presentes em problemas reais.

Historicamente, os primeiros experimentos com otimização de quatro ou mais objetivos datam do início dos anos 1990, com algoritmos como o Multi-Objective Genetic Algorithms - MOGA, aplicado por exemplo em um problema de projeto de turbina a gás com quatro objetivos ([MURATA; ISHIBUCHI, 1995](#)). A partir daquele ponto, houve um

rápido crescimento na pesquisa dedicada ao tema — particularmente na última década — com inúmeros algoritmos sendo propostos, tais como os baseados em decomposição, seleção por indicadores de qualidade e vetor de referência. (CHAND; WAGNER, 2015) oferece uma visão abrangente sobre esses desenvolvimentos, listando benchmarks usados, algoritmos mais promissores e orientações para futuras pesquisas em aplicações reais de many-objective optimization.

O AEMMT (Algoritmo Evolutivo Multiobjetivo com Muitas Tabelas) foi desenvolvido inicialmente para problemas com quatro objetivos, como a predição de estruturas de proteínas, em que algoritmos tradicionais falhavam (BRASIL; DELBEM; SILVA, 2013). Ele organiza a população em diversas tabelas (ou subpopulações), formadas por subconjuntos de objetivos, usando como critério de inserção a média ponderada das funções objetivo — com exceção da tabela de não dominância (ND), que aceita apenas indivíduos não dominados por nenhum outro. Já o AEMMD (Algoritmo Evolutivo Multiobjetivo com Múltiplas Dominâncias) propõe modificações ao AEMMT: substitui a métrica de média ponderada por dominância em todas as tabelas, elimina o limite de tamanho das tabelas e utiliza um sistema de pontuação por convergência em vez de contribuição (LAFETÁ, 2016). Além disso, reduz a quantidade de tabelas necessárias, tornando o processo mais enxuto e focado em conjuntos de dois ou mais objetivos. Por fim, o MOEA/D (Algoritmo Evolutivo Multiobjetivo Baseado em Decomposição) adota uma abordagem distinta, decompondo o problema original em subproblemas escalarizados, um para cada indivíduo da população (HE; YEN; ZHANG, 2014). Cada solução é associada a um vetor de pesos e interage apenas com vizinhos próximos definidos por distância euclidiana. As soluções são combinadas e avaliadas com base em funções como Soma Ponderada, Tchebycheff ou PBI, e os indivíduos não dominados são armazenados em um arquivo separado, que representa a fronteira de Pareto aproximada ao final do processo.




Figura 1 – Aprovação Orientador



# REFERÊNCIAS

BRASIL, C. R. S.; DELBEM, A. C. B.; SILVA, F. L. B. d. Multiobjective evolutionary algorithm with many tables for purely *ab initio* protein structure prediction. *Journal of Computational Chemistry*, Wiley Online Library, v. 34, n. 20, p. 1719–1734, 2013. Citado na página 7.

BUENO, M. L.; OLIVEIRA, G. M. Multicast flow routing: Evaluation of heuristics and multiobjective evolutionary algorithms. In: *IEEE Congress on Evolutionary Computation*. IEEE, 2010. p. 1–8. Disponível em: <<https://doi.org/10.1109/CEC.2010.5585942>>. Citado na página 5.

CHAND, S.; WAGNER, M. Evolutionary many-objective optimization: A quick-start guide. *Surveys in Operations Research and Management Science*, Elsevier BV, v. 20, n. 2, p. 35–42, Dec 2015. Disponível em: <[https://www.sciencedirect.com/science/article/abs/pii/S1876735415000148?utm\\_source=chatgpt.com](https://www.sciencedirect.com/science/article/abs/pii/S1876735415000148?utm_source=chatgpt.com)>. Citado 2 vezes nas páginas 6 e 7.

COELLO, C. A. C. Evolutionary multi-objective optimization: some current research trends and topics that remain to be explored. *Frontiers of Computer Science in China*, Springer, v. 3, n. 1, p. 18–30, 2009. Citado 3 vezes nas páginas 3, 4 e 6.

DEB, K. *Multi-Objective Optimization Using Evolutionary Algorithms*. [S.l.]: Wiley, 2001. 518 p. ISBN 9780471873396. Citado na página 5.

EIBEN, A.; SMITH, J. Introduction to evolutionary computing. *SpringerLink*, Springer Berlin Heidelberg, 2015. Disponível em: <<https://link.springer.com/book/10.1007/978-3-662-44874-8>>. Citado na página 3.

GABRIEL, P. H. R.; DELBEM, A. C. B. *Fundamentos de algoritmos evolutivos*. [S.l.]: ICMC-USP, 2008. Citado na página 3.

GOLDBERG, D. E. *Genetic Algorithms in Search, Optimization, and Machine Learning*. Boston, MA, USA: Addison-Wesley Pub. Co., 1989. 412 p. ISBN 0201157675. Citado na página 5.

GOULART, F.; CAMPELO, F. Preference-guided evolutionary algorithms for many-objective optimization. *Information Sciences*, v. 329, p. 236–255, 2016. ISSN 0020-0255. Special issue on Discovery Science. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0020025515006696>>. Citado na página 6.

HE, Z.; YEN, G. G.; ZHANG, J. Fuzzy-based pareto optimality for many-objective evolutionary algorithms. *IEEE Transactions on Evolutionary Computation*, IEEE, v. 18, n. 2, p. 269–285, 2014. Citado na página 7.

HOLLAND, J. *Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence*. MIT Press, 1992. (Complex Adaptive Systems). ISBN 9780262581110. Disponível em: <<https://books.google.com.br/books?id=5EgGaBkwvWcC>>. Citado na página 3.

LAFETÁ, T. F. d. Q. *Algoritmos evolutivos many objectives aplicados ao problema de roteamento multicast com qualidade de serviço*. Dissertação (Dissertação de Mestrado) — Universidade Federal de Uberlândia, 2016. Citado na página 7.

MARSON, G. A. et al. Análise comparativa dos algoritmos genéticos many-objective em problemas de otimização discreta. Universidade Federal de Uberlândia, 2017. Citado na página 4.

MURATA, T.; ISHIBUCHI, H. Moga: Multi-objective genetic algorithms. In: *IEEE International Conference on Evolutionary Computation*. IEEE, 1995. v. 1, p. 289. Disponível em: <<https://doi.org/10.1109/ICEC.1995.489161>>. Citado na página 6.

NASCIMENTO, G. V. Algoritmo evolutivo multiobjetivo com medida de uniformidade no espaço de decisão aplicado no problema da dieta. 2025. Citado na página 6.

OVERLEAF. *Tutorials - Overleaf, Editor LaTeX*. 2025. Disponível em: <<https://pt.overleaf.com/learn/latex/Tutorials>>. Citado na página 1.

VELDHUIZEN, D. A. V.; LAMONT, G. B.; OVELDHUIZENTHERS. Evolutionary computation and convergence to a pareto front. In: *Late breaking papers at the genetic programming 1998 conference*. [S.l.: s.n.], 1998. p. 221–228. Citado na página 4.

ZITZLER, E.; LAUMANN, M.; THIELE, L. *SPEA2: Improving the Strength Pareto Evolutionary Algorithm*. [S.l.], 2001. Disponível em: <<https://doi.org/10.3929/ethz-a-004284029>>. Citado na página 5.